

可解释肺结节恶性评分

Prediction、WHERE、WHAT、WHY 与 HOW

Author / 作者: [To be completed]

Affiliation / 单位: [To be completed]

Supervisor / 导师: [To be completed]

Date / 日期: 2026-08-13

目录

摘要	6
1. 引言	6
2. 相关工作	7
3. 数据集与预处理	7
4. 方法	8
5. 实验设置	9
6.1 结果——Prediction	10
6.2 结果——WHERE	13
6.3 结果——WHAT	16
6.4 结果——WHY	17
6.5 结果——HOW	21
6.6 综合解释	22
7. 讨论	23
8. 局限性	23
9. 结论	24
公开可复现性附录	24
参考文献	24

图表目录

RPT-T01. 相关工作比较

RPT-T02. 冻结队列流程

RPT-T03. 目标与概念定义

RPT-T04. 四模型架构比较

RPT-T05. 冻结训练配置与完成情况

RPT-T06. 评估协议

RPT-T07. 主要回归结果

RPT-T08. 六组配对 Delta-MAE 比较

RPT-T09. 极端任务性能

RPT-T10. 六组配对 Delta-AUROC 比较

RPT-T11. 连续概念指标

RPT-T12. 分类概念指标

RPT-T13. Grad-CAM 总账

RPT-T14. 空间忠实度

RPT-T15. 中心化贡献汇总

RPT-T16. Learned-softmax GAM 逐折 alpha

RPT-T17. 概念干预汇总

RPT-T18. WHERE-WHAT-WHY-HOW 综合表

RPT-F01. 从预测串联 WHERE、WHAT、WHY 与 HOW 的端到端证据框架。

RPT-F02. 冻结队列、局部 ROI 预处理与患者分组五折评估流程。

RPT-F03. 四种模型架构及其预注册解释接口。

RPT-F04. 主要 pooled MAE 及 2,000 次患者聚类 bootstrap 95% 区间。

RPT-F05. 六组配对 Delta-MAE 比较，并区分跨零区间。

RPT-F06. 极端任务 AUROC/AUPRC 与六组配对 Delta-AUROC。

RPT-F07. 按模型、折和目标分解的 post-ReLU 全零 Grad-CAM 比例。

RPT-F08. output_sensitivity 与 error_increase 相对匹配随机遮挡的空间忠实度。

RPT-F09A. 使用独立指标量尺呈现连续概念忠实度。

RPT-F09B. 使用独立指标量尺呈现分类概念忠实度。

RPT-F10. 经验 OOF 贡献剖面；仅为描述性呈现，并非因果 shape function。

RPT-F11. Learned-softmax GAM 的逐折专家混合权重。

RPT-F12. 随机顺序与 error-first 顺序下的 $k=0\cdots 8$ 概念干预曲线。

RPT-F13. Prediction-WHERE-WHAT-WHY-HOW 的综合解释及其边界。

缩写表

CBM — Concept Bottleneck Model; CEM — Concept Embedding Model; GAM — Generalized Additive Model;
OOF — out-of-fold; ROI — region of interest; MAE — mean absolute error; RMSE — root mean squared error;
AUROC — area under the receiver-operating-characteristic curve; AUPRC — area under the precision-recall curve.

摘要

本研究在冻结的 2,633 个结节、868 名患者队列上，比较四种用于放射科医师评估肺结节恶性程度的三维深度学习策略。主要终点是在原始 1–5 评分量尺上的 pooled OOF 平均绝对误差；次要证据包括 1,073 个极端结节、八个瓶颈概念、中心化评分贡献、概念干预与空间 Grad-CAM 忠实度。报告按 Prediction、WHERE、WHAT、WHY、HOW 组织，而不是按审计清单堆叠结果。



同一冻结 OOF 证据链

RPT-F01. 从预测串联 WHERE、WHAT、WHY 与 HOW 的端到端证据框架。

Learned-softmax GAM 的主要 MAE 点估计最低，为 0.480；Black-box 为 0.501。四个模型共请求 73,724 个 Grad-CAM 目标，其中 66,769 个有效，6,955 个被明确记录为 post-ReLU 全零图。匹配随机遮挡表明，空间显著性并非始终比随机遮挡更忠实；概念干预的变化则依赖模型与排序方式。

这些结果支持分层解释：较好的预测本身不能证明空间或概念忠实度；概念预测较准也不保证干预有益；加性贡献分解能够描述模型评分，但不建立临床因果关系。恶性程度是放射科医师评估，并非病理确诊；本系统不是临床诊断产品。

1. 引言

肺结节恶性程度评估同时包含预测问题与解释问题。数值恶性评分可用于基准比较，但读者还需要知道图像的哪些位置影响模型、模型表示了哪些影像学概念、这些表示为何改变输出，以及在纠正概念信息时输出如何变化。若把这些证据视为同一种“解释”，就会掩盖它们不同的证据角色。

因此，本研究围绕五个相互连接的问题组织分析。Prediction 关注连续的放射科医师评估目标能否被准确估计；WHERE 使用 Grad-CAM 与匹配遮挡评估空间敏感性；WHAT 衡量六个连续概念和两个分类概念的预测忠实度；WHY 把概念模型评分分解为仅由训练折统计量中心化的有符号贡献与学习到的局部专家混合；HOW 通过预注册概念干预测试模型依赖。

本研究不是新的临床分类器，也不声称达到病理诊断层级。它在相同患者分组折、共享编码器初始化、test exactly-once 和统一 OOF 分析下，比较 Black-box、Standard CBM、项目特定 Mixed-type CEM 与预注册 Learned-softmax GAM。报告保留负面结果，包括不确定的配对 AUROC 差异、有限的分类概念忠实度、依赖模型的干预收益，以及集中的全零图现象。

2. 相关工作

三维卷积网络能够把体积 CT patch 直接映射为恶性评分，但其内部表示并不天然对应影像学术语。Dense connectivity 有助于特征复用与梯度传播，因此四个模型共享 DenseNet-121 编码器。Black-box 模型用于建立不施加概念约束时的图像优先基准。

RPT-T01. 相关工作比较

Approach	Prediction	Concepts	Spatial explanation	Intervention	This study
Black-box CNN	Yes	No	Optional	No	Comparator
Concept Bottleneck Model	Yes	Explicit	Concept/task Grad-CAM	Concept replacement	Standard CBM
Concept Embedding Model	Yes	Mixed-type embeddings	Concept/task Grad-CAM	Mixture-weight replacement	Project-specific Mixed-type CEM
Additive local experts	Yes	Explicit	Concept/task Grad-CAM	Local-expert re-evaluation	Preregistered Learned-soft max GAM

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T01.csv.

概念瓶颈模型暴露可评估、可干预的中间变量。概念嵌入模型通过构造样本条件化概念状态放宽标量瓶颈，而本项目进一步扩展到连续与分类读者目标混合的情形。Learned-softmax GAM 则保留显式概念预测，并把每组概念送入五个局部专家，其混合权重在每折学习。

Grad-CAM 在卷积特征层定位梯度，但视觉上集中的热图并不自动等于忠实解释。因此，本研究把确定性显著区域遮挡与 20 个等大小随机遮挡比较，并同时保存 output_sensitivity 和 error_increase。二者区别至关重要：输出发生变化并不能证明预测变差。表 RPT-T01 对这些组成进行定位，但不会把既往研究结果当作当前队列证据。

3. 数据集与预处理

本研究使用 LIDC-IDRI XML 读者标注与稳定的实体结节身份。冻结主要队列包含 2,633 个结节、868 名患者；其中 1,073 个结节、578 名患者满足预注册极端定义，包括 782 个低分结节与 291 个高分结节。Patient Diagnoses XLS 不参与训练；恶性程度是有效放射科医师评分均值，而不是病理确诊标签。

RPT-T02. 冻结队列流程

Cohort component	Nodules	Patients	Role
Reference physical nodules	2651	875	Reconciliation only
Missing required target	1	NA	Excluded
Primary regression	2633	868	Main five-fold evaluation
Secondary extreme subset	1073	578	782 low / 291 high

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T02.csv.

Malignancy 是下游 1 – 5 目标，不属于八个瓶颈概念。八个概念为 subtlety、internalStructure、calcification、sphericity、margin、lobulation、spiculation 和 texture。六个目标是连续的归一化读者均值；internalStructure 与 calcification 保留完整读者投票分布，训练与 soft metrics 中包括真实众数并列。


RPT-T03. 目标与概念定义

Variable	Role	Type	Frozen target
Malignancy	Downstream target (not a concept)	Continuous	Radiologist mean, 1 – 5; normalized (y–1)/4
subtlety	Bottleneck concept	Continuous	Normalized valid-reader mean
sphericity	Bottleneck concept	Continuous	Normalized valid-reader mean
margin	Bottleneck concept	Continuous	Normalized valid-reader mean
lobulation	Bottleneck concept	Continuous	Normalized valid-reader mean

Variable	Role	Type	Frozen target
spiculation	Bottleneck concept	Continuous	Normalized valid-reader mean
texture	Bottleneck concept	Continuous	Normalized valid-reader mean
internalStructure	Bottleneck concept	Categorical (4 classes)	Full reader vote distribution
calcification	Bottleneck concept	Categorical (6 classes)	Full reader vote distribution

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T03.csv.

每个模型接收 $64 \times 64 \times 64$ 的局部肺结节 ROI，该输入由 consensus mask 裁剪、立方体 padding 与确定性重采样生成。ROI 不是完整轴位 CT slice，经过裁剪与重采样后可能显得分辨率更低。只有在冻结的 series、slice、bounding box 与坐标 provenance 完整时，完整轴位 CT 才用于私有上下文可视化。图 RPT-F02 与表 RPT-T02 – RPT-T03 展示本研究队列与变量。



RPT-F02. 冻结队列、局部 ROI 预处理与患者分组五折评估流程。

4. 方法

四个模型共享同一逐折 DenseNet-121 编码器初始化，并使用无约束线性恶性输出。训练和评估不使用 sigmoid、tanh 或 clipping。Black-box 直接把编码器特征映射为评分；Standard CBM 先学习八个概念，再用冻结的预测概念拟合线性 task head；Mixed-type CEM 为连续与分类概念构造样本条件化状态；Learned-softmax GAM 对每个预测概念组使用五个局部专家，并相加其 softmax 加权输出。

RPT-T04. 四模型架构比较

Model	Task path	Concept representation	Contribution semantics	Intervention semantics
Black-box	DenseNet features $\rightarrow$ linear score	None	Not applicable	Not applicable
Standard CBM	Predicted concepts $\rightarrow$ linear score	6 sigmoid + 2 softmax groups	Linear group terms	Replace activated concept group
Mixed-type CEM	Sample-conditioned concept embeddings $\rightarrow$ linear score	Mixed-type dynamic states	Embedding block dot product	Replace mixture weights only
Learned-softmax GAM	Predicted concepts $\rightarrow$ local experts $\rightarrow$ additive score	6 sigmoid + 2 softmax groups	Softmax-weighted local experts	Ground-truth concept through experts

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T04.csv.


概念模型贡献使用仅由当前训练折计算的均值进行中心化。中心化 bias 与八个中心化贡献重建归一化评分；把贡献乘以 4 后重建原始评分点量尺。这些有符号项描述训练模型如何组成输出；centering constants 是记账统计量，不是特征重要性。未持久化的 mean absolute aggregate 不会为展示而重算。

RPT-T06. 评估协议

Component	Unit	Metric	Selection/uncertainty
Primary regression	Nodule; patient-cluster bootstrap	Unclipped original-scale MAE (primary), RMSE, normalized MAE, Pearson, Spearman	2,000 shared patient draws
Secondary extreme	1,073 extreme nodules / 578 patients	AUROC, AUPRC; threshold metrics	Fold-validation extreme-only Youden-J; 2,000 valid draws
Concept fidelity	Nodule	Continuous MAE/RMSE/correlation; categorical CE/Brier/macro-F1	Hard F1 excludes true modal ties
Spatial faithfulness	Valid Grad-CAM target	output_sensitivity and error_increase	26,215 voxels; 20 matched random masks
Intervention	Pooled OOF	iMAE/Delta_iMAE; iAUC/Delta_iAUC	k=0...8; random and error-first orderings

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T06.csv.

Grad-CAM 使用最终预注册卷积层、空间均值梯度、加权 activation 求和、ReLU 与到 64^3 的三线性上采样。原始 FP32 map 保持为科学产物；display overlay 只允许为了可视化进行归一化。post-ReLU 全零图被标记为 undefined，并从遮挡分母中排除；冻结产物未保存 pre-ReLU、gradient norm、activation norm 或 channel-weight decomposition，因此无法推断精确机制。



RPT-F03. 四种模型架构及其预注册解释接口。

遮挡把热图最高的 26,215 个 voxel 置为归一化零，并与 20 个等大小、全 ROI 均匀无放回随机遮挡比较。output_sensitivity 是输出绝对移动；error_increase 是绝对目标误差的变化，只有正值表示预测误差变大。干预曲线在共享随机 permutation 或 error-first 排序下替换 0...8 个概念组；正 Delta_iMAE 与 Delta_iAUC 始终表示改善。图 RPT-F03 与表 RPT-T04、RPT-T06 汇总这些预注册语义。

5. 实验设置

评估采用患者分组五折 outer cross-validation，固定 test 结节数为 479、502、539、549、564。每折 partition 内患者互斥，每个主要结节在 canonical OOF test set 中恰好出现一次。逐折 validation subset 用于选择 checkpoint 和 Youden-J threshold；test labels 不参与任何选择。

RPT-T05. 冻结训练配置与完成情况

Model	Fold	Best epoch	Epochs complete	Test transactions	Scientific status
Black-box	0	14	NA	1	PASS
Black-box	1	19	NA	1	PASS
Black-box	2	10	NA	1	PASS
Black-box	3	15	NA	1	PASS
Black-box	4	38	NA	1	PASS
Standard CBM	0	concept=10;task=78	NA	1	PASS

Model	Fold	Best epoch	Epochs complete	Test transactions	Scientific status
Standard CBM	1	concept=16;task=79	NA	1	PASS
Standard CBM	2	concept=38;task=77	NA	1	PASS
Standard CBM	3	concept=6;task=79	NA	1	PASS
Standard CBM	4	concept=18;task=78	NA	1	PASS
Mixed-type CEM	0	28	NA	1	PASS
Mixed-type CEM	1	21	NA	1	PASS
Mixed-type CEM	2	18	NA	1	PASS
Mixed-type CEM	3	15	NA	1	PASS
Mixed-type CEM	4	44	NA	1	PASS
Learned-softmax GAM	0	10	NA	1	PASS
Learned-softmax GAM	1	28	NA	1	PASS
Learned-softmax GAM	2	32	NA	1	PASS
Learned-softmax GAM	3	15	NA	1	PASS
Learned-softmax GAM	4	22	NA	1	PASS
Black-box	None	NA	NA	1	PASS
Learned-softmax GAM	None	NA	NA	1	PASS
Mixed-type CEM	None	NA	NA	1	PASS
Standard CBM	None	NA	NA	1	PASS

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T05.csv.

每个 model/fold 训练使用一个冻结 seed，最多 80 epochs。固定 best checkpoint 后，test evaluation 只提交一次。历史 scheduler failure 和 verifier recovery 作为 provenance 保留，但与科学有效性明确区分；报告阶段绝不覆盖已完成的 history、checkpoint、prediction、metric 或 evaluation。

RPT-T06. 评估协议

Component	Unit	Metric	Selection/uncertainty
Primary regression	Nodule; patient-cluster bootstrap	Unclipped original-scale MAE (primary), RMSE, normalized MAE, Pearson, Spearman	2,000 shared patient draws
Secondary extreme	1,073 extreme nodules / 578 patients	AUROC, AUPRC; threshold metrics	Fold-validation extreme-only Youden-J; 2,000 valid draws
Concept fidelity	Nodule	Continuous MAE/RMSE/correlation; categorical CE/Brier/macro-F1	Hard F1 excludes true modal ties
Spatial faithfulness	Valid Grad-CAM target	output_sensitivity and error_increase	26,215 voxels; 20 matched random masks
Intervention	Pooled OOF	iMAE/Delta_iMAE; iAUC/Delta_iAUC	k=0...8; random and error-first orderings

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T06.csv.

不确定性使用 2,000 次患者聚类 bootstrap，配对比较共享患者 draws。每个被抽中的患者携带其全部结节；若 secondary AUROC draw 只有单一类别，则重新抽样。表 RPT-T05 记录逐折完成情况；表 RPT-T06 把统计定义与执行历史分开。

6.1 结果——Prediction

测量内容是什么？主要预测在全部 2,633 个 OOF 结节上评估，以原始量尺 MAE 为主要终点。Learned-softmax GAM 的点估计最低 (0.480)，随后为 Mixed-type CEM (0.484)、Black-box (0.501) 与 Standard CBM (0.502)。表 RPT-T07 报告全部冻结回归点估计及既有 2,000-draw 区间；图 RPT-F04 直观展示不确定性重叠。

RPT-T07. 主要回归结果

Model	MAE (95% CI)	RMSE (95% CI)	Normalized MAE (95% CI)	Pearson (95% CI)	Spearman (95% CI)	Prediction range (1 – 5)	N
Black-box	0.501 (0.483 – 0.520)	0.642 (0.619 – 0.667)	0.125 (0.121 – 0.130)	0.716 (0.689 – 0.741)	0.635 (0.599 – 0.668)	0.489 – 5.120	2633
Learned-softmax GAM	0.480 (0.462 – 0.498)	0.618 (0.592 – 0.642)	0.120 (0.116 – 0.125)	0.741 (0.712 – 0.768)	0.653 (0.616 – 0.688)	1.008 – 4.682	2633
Mixed-type CEM	0.484 (0.467 – 0.502)	0.628 (0.604 – 0.654)	0.121 (0.117 – 0.126)	0.730 (0.701 – 0.757)	0.640 (0.604 – 0.673)	0.823 – 4.935	2633
Standard CBM	0.502 (0.483 – 0.522)	0.650 (0.625 – 0.675)	0.126 (0.121 – 0.131)	0.708 (0.677 – 0.735)	0.609 (0.570 – 0.648)	0.858 – 4.580	2633

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T07.csv.

观察到了什么？配对 Delta-MAE 支持 Learned-softmax GAM 优于 Black-box 和 Standard CBM，因为对应区间不跨零；较小差异则需要谨慎解读。Black-box 与 Standard CBM 的区间跨零，说明加入解释结构并不会自动改善点预测。表 RPT-T08 与图 RPT-F05 保留全部六组比较以及 MAE_A – MAE_B 符号约定。

RPT-T08. 六组配对 Delta-MAE 比较

Comparison (A vs B)	Delta-MAE (A–B)	95% CI	Crosses zero	Direction
Black-box vs Learned-softmax GAM	0.020	0.010 – 0.031	False	Positive supports B
Black-box vs Mixed-type CEM	0.016	0.006 – 0.027	False	Positive supports B
Black-box vs Standard CBM	-0.002	-0.015 – 0.012	True	Positive supports B
Mixed-type CEM vs Learned-softmax GAM	0.004	-0.006 – 0.013	True	Positive supports B
Standard CBM vs Learned-softmax GAM	0.022	0.011 – 0.033	False	Positive supports B
Standard CBM vs Mixed-type CEM	0.018	0.006 – 0.030	False	Positive supports B

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T08.csv.

在 1,073 个结节的极端子集上，四个连续评分均能区分低分与高分，但配对 Delta-AUROC 证据不如 MAE 证据明确。多个区间跨零；在预注册 B–A 约定下，Standard CBM 低于 Black-box。因此，表 RPT-T09、表 RPT-T10 与图 RPT-F06 把绝对 AUROC/AUPRC 性能和模型间不确定性分开。

RPT-T09. 极端任务性能

Model	AUROC (95% CI)	AUPRC (95% CI)	Sensitivity	Specificity	Balanced accuracy	N
Black-box	0.945 (0.926 – 0.962)	0.894 (0.859 – 0.925)	0.801	0.927	0.864	1073
Learned-softmax GAM	0.949 (0.927 – 0.968)	0.903 (0.868 – 0.934)	0.859	0.894	0.876	1073
Mixed-type CEM	0.942 (0.920 – 0.960)	0.877 (0.833 – 0.916)	0.832	0.923	0.877	1073
Standard CBM	0.933 (0.911 – 0.951)	0.866 (0.826 – 0.900)	0.825	0.866	0.845	1073


完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T09.csv.

这意味着什么？Learned-softmax GAM 是本实验 midpoint 估计最好的回归模型，但该结果不能支持跨终点的普遍排名。未裁剪评分范围与少量越界比例属于模型行为的一部分，不应被 post-hoc clipping 隐藏。目标是放射科医师均值，因此预测精度不能解释为病理层级诊断精度。


RPT-T10. 六组配对 Delta-AUROC 比较

Comparison (A vs B)	Delta-AUROC (B–A)	95% CI	Crosses zero	Direction
Black-box vs Learned-softmax GAM	0.004	-0.005 – 0.014	True	Positive supports B
Black-box vs Mixed-type CEM	-0.004	-0.013 – 0.005	True	Positive supports B
Black-box vs Standard CBM	-0.013	-0.022 – -0.004	False	Positive supports B
Mixed-type CEM vs Learned-softmax GAM	0.008	-0.001 – 0.018	True	Positive supports B
Standard CBM vs Learned-softmax GAM	0.017	0.006 – 0.027	False	Positive supports B
Standard CBM vs Mixed-type CEM	0.009	-0.002 – 0.020	True	Positive supports B


完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T10.csv.



RPT-F04. 主要 pooled MAE 及 2,000 次患者聚类 bootstrap 95% 区间。



RPT-F05. 六组配对 Delta-MAE 比较，并区分跨零区间。



RPT-F06. 极端任务 AUROC/AUPRC 与六组配对 Delta-AUROC。

科学结论代码: GAM_LOWEST_POINT_ESTIMATE_MAE, PAIRED_MAE_SUPPORTS_GAM_OVER_BLACKBOX_AND_CBM, AUROC_DIFFERENCES_MOSTLY_UNCERTAIN

6.2 结果——WHERE

测量内容是什么？空间证据覆盖全部 model、fold、target 组合，共请求 73,724 个 Grad-CAM map。其中 66,769 个有效，6,955 个为 post-ReLU 全零图，总 undefined rate 为 9.434%。表 RPT-T13 给出完整总账；图 RPT-F07 展示 pooled count 会掩盖的集中分布。

RPT-T13. Grad-CAM 总账

Model	Fold	Target	Requested	Valid	Undefined	Undefined rate
Mixed-type CEM	0	malignancy	479	102	377	0.787
Mixed-type CEM	4	internalStructure	564	167	397	0.704
Mixed-type CEM	0	internalStructure	479	170	309	0.645
Mixed-type CEM	4	malignancy	564	203	361	0.640
Learned-softmax GAM	3	calcification	549	198	351	0.639
Standard CBM	0	calcification	479	183	296	0.618
Mixed-type CEM	2	malignancy	539	213	326	0.605
Mixed-type CEM	1	calcification	502	202	300	0.598
Standard CBM	1	calcification	502	309	193	0.384
Mixed-type CEM	1	malignancy	502	318	184	0.367
Mixed-type CEM	4	calcification	564	368	196	0.348
Mixed-type CEM	2	internalStructure	539	362	177	0.328
Learned-softmax GAM	2	spiculation	539	367	172	0.319
Mixed-type CEM	4	sphericity	564	384	180	0.319
Standard CBM	4	calcification	564	405	159	0.282
Mixed-type CEM	0	calcification	479	356	123	0.257
Learned-softmax GAM	3	spiculation	549	410	139	0.253
Mixed-type CEM	2	lobulation	539	405	134	0.249
Learned-softmax GAM	4	calcification	564	435	129	0.229
Learned-softmax GAM	3	lobulation	549	426	123	0.224
Learned-softmax GAM	3	malignancy	549	426	123	0.224
Mixed-type CEM	3	malignancy	549	431	118	0.215
Standard CBM	0	internalStructure	479	382	97	0.203
Black-box	3	malignancy	549	448	101	0.184

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T13.csv.


观察到了什么？undefined maps 并非均匀分布，而是集中在特定 model-target 组合，因此冻结 root-cause label 是 SYSTEMATIC_MODEL/TARGET_ISSUE，而不是笼统的 implementation failure。所有 undefined map 均为 finite 且 ReLU 后精确全零；没有观察到 NaN、Inf、loading error 或 target-path mismatch。然而，持久化产物未包含 pre-ReLU CAM 或 gradient/channel-weight norm。

RPT-T14. 空间忠实度

Model	Target	Quantity	Saliency mean	Saliency median	Saliency-random mean	Saliency > random rate	Valid maps
Black-box	malignancy	output_sensitivity	0.025	0.017	-0.323	0.009	2429
Black-box	malignancy	error_increase	0.003	0.000	-0.235	0.144	2429
Learned-softmax GAM	malignancy	output_sensitivity	0.025	0.020	-0.302	0.004	2361
Learned-softmax GAM	malignancy	error_increase	0.002	0.000	-0.214	0.157	2361
Mixed-type CEM	malignancy	output_sensitivity	0.026	0.020	-0.318	0.007	1267
Mixed-type CEM	malignancy	error_increase	0.005	0.003	-0.247	0.154	1267
Standard CBM	malignancy	output_sensitivity	0.018	0.012	-0.218	0.005	2398
Standard CBM	malignancy	error_increase	0.003	0.001	-0.140	0.227	2398

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T14.csv.


忠实度给出了具有科学意义的负面结果。对 output_sensitivity 与 error_increase 而言，pooled saliency-minus-random mean 经常为负；只有少数有效 case 中显著区域超过匹配随机均值。表 RPT-T14 与图 RPT-F08 把输出移动和预测误差恶化分开。较大的 output_sensitivity 本身不能证明预测准确度下降。



RPT-F07. 按模型、折和目标分解的 post-ReLU 全零 Grad-CAM 比例。

这意味着什么？Grad-CAM 是空间敏感度 proxy，不是 ground-truth localisation claim。即使 task prediction 准确，全零图集中与较弱的 matched-random 优势也限制了强空间解释。Display overlay 仅为定性阅读进行归一化；所有定量遮挡结果仍使用原始未归一化 FP32 map。

空间忠实度：显著区域与匹配随机遮挡



RPT-F08. output_sensitivity 与 error_increase 相对匹配随机遮挡的空间忠实度。

科学结论代码: SALIENCY_NOT_UNIFORMLY_MORE_FAITHFUL_THAN_RANDOM,
SYSTEMATIC_MODEL_TARGET_ZERO_MAP_LIMITATION

6.3 结果——WHAT

测量内容是什么？连续概念忠实度在每个概念模型的 2,633 个结节上使用 MAE、RMSE、Pearson 与 Spearman。分类概念忠实度在完整读者投票分布上使用 soft cross-entropy 与 multiclass Brier，并仅在真实众数类别唯一时计算 hard modal macro-F1。表 RPT-T11 与图 RPT-F09A 让连续指标使用兼容量尺；表 RPT-T12 与图 RPT-F09B 对分类证据采用同样策略。

RPT-T11. 连续概念指标

Model	Concept	MAE	RMSE	Pearson	Spearman	N
Learned-softmax GAM	lobulation	0.127	0.190	0.451	0.472	2633
Learned-softmax GAM	margin	0.145	0.198	0.683	0.648	2633
Learned-softmax GAM	sphericity	0.140	0.178	0.424	0.435	2633
Learned-softmax GAM	spiculation	0.114	0.184	0.499	0.456	2633
Learned-softmax GAM	subtlity	0.168	0.221	0.578	0.582	2633
Learned-softmax GAM	texture	0.111	0.179	0.786	0.583	2633
Mixed-type CEM	lobulation	0.183	0.218	0.270	0.249	2633
Mixed-type CEM	margin	0.246	0.292	0.188	0.171	2633
Mixed-type CEM	sphericity	0.178	0.217	0.056	0.051	2633
Mixed-type CEM	spiculation	0.180	0.216	0.305	0.274	2633
Mixed-type CEM	subtlity	0.204	0.250	0.445	0.449	2633
Mixed-type CEM	texture	0.265	0.305	0.202	0.167	2633
Standard CBM	lobulation	0.131	0.186	0.460	0.456	2633
Standard CBM	margin	0.146	0.197	0.687	0.647	2633
Standard CBM	sphericity	0.139	0.177	0.437	0.453	2633
Standard CBM	spiculation	0.121	0.182	0.507	0.416	2633
Standard CBM	subtlity	0.169	0.223	0.567	0.573	2633
Standard CBM	texture	0.116	0.180	0.783	0.581	2633

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T11.csv.


观察到了什么？连续忠实度随 concept 与 model 显著变化，并不存在单一的全模型模式。部分形态学概念表现出有用相关性，而更微妙或读者变异较大的概念保留较高绝对误差。这种异质性很重要，因为下游概念模型只能解释自身预测表示，而不是无误差的影像学真实状态。

RPT-T12. 分类概念指标

Model	Concept	Soft CE	Brier	Macro-F1	Soft N	Hard N	Ties
Learned-softmax GAM	calcification	0.201	0.048	0.313	2633	2578	55
Learned-softmax GAM	internalStructure	0.038	0.007	0.312	2633	2625	8
Mixed-type CEM	calcification	0.262	0.068	0.310	2633	2578	55
Mixed-type CEM	internalStructure	0.083	0.014	0.250	2633	2625	8
Standard CBM	calcification	0.207	0.049	0.314	2633	2578	55
Standard CBM	internalStructure	0.039	0.007	0.250	2633	2625	8


完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T12.csv.

分类结果更有限。internalStructure 与 calcification 保留完整投票分布，因此 soft loss 与 Brier score 是权威分布证据。hard modal macro-F1 便于阅读，但排除真实并列，在稀有类别困难时可能较低。把 modal label 当作单一专家 ground truth 会错误描述冻结目标。



RPT-F09A. 使用独立指标量尺呈现连续概念忠实度。

这意味着什么？WHAT 证据支持逐组检查概念，而不是笼统声称模型已经统一学会影像学概念。概念忠实度是透明瓶颈的必要条件，但不足以保证预测优势或干预收益。因此，私有 RPT-TA02 在病例层面同时呈现连续目标与分类投票分布语义。



RPT-F09B. 使用独立指标量尺呈现分类概念忠实度。

6.4 结果——WHY

测量内容是什么？WHY 证据关注预测概念如何进入每个概念模型的恶性评分。每一折使用 train-only mean 对原始 group term 进行中心化；中心化 bias 与八个 term 在冻结 1e-6 tolerance 内重建 task score。表 RPT-T15 记录 pooled signed mean 与逐折 centering constants，但不会把它们改称 importance。

RPT-T15. 中心化贡献汇总

Model	Concept	Pooled signed mean (rating points)	Fold train-centering constants (rating points)	Mean contribution	Interpretation
Learned-softmax GAM	calcification	0.402	0.450; 0.247; 0.397; 0.498; 0.419	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	internalStructure	0.041	-0.275; 0.289; 0.032; -0.160; 0.321	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	lobulation	-0.016	0.336; 0.133; -0.834; -0.039; 0.325	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	margin	0.370	0.526; 0.290; 0.647; 0.226; 0.162	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	sphericity	0.106	-0.127; 0.055; 0.449; 0.109; 0.045	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance

Model	Concept	Pooled signed mean (rating points)	Fold train-centering constants (rating points)	Mean contribution	Interpretation
Learned-softmax GAM	spiculation	0.323	0.058; 0.178; 0.502; 0.611; 0.265	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	subtlety	0.229	0.254; 0.172; 0.257; 0.160; 0.299	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Learned-softmax GAM	texture	0.190	0.355; 0.351; 0.181; 0.275; -0.209	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	calcification	0.263	0.215; 0.511; 0.245; 0.201; 0.146	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	internalStructure	0.486	0.371; 0.153; 0.585; 0.473; 0.848	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	lobulation	0.279	0.321; 0.155; 0.217; 0.390; 0.310	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	margin	0.123	0.219; 0.046; 0.007; 0.338; 0.006	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	sphericity	0.155	0.440; 0.057; 0.188; 0.090; -0.001	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	spiculation	0.141	0.042; 0.195; 0.213; 0.112; 0.145	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	subtlety	0.133	-0.039; 0.185; 0.298; 0.091; 0.127	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Mixed-type CEM	texture	0.101	0.147; 0.221; 0.044; 0.045; 0.050	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	calcification	0.400	0.941; 0.633; 0.387; 0.145; -0.104	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	internalStructure	0.281	-0.005; 0.479; 0.482; -0.254; 0.704	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	lobulation	0.246	0.260; 0.129; 0.211; 0.243; 0.385	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	margin	0.137	0.152; -0.041; -0.131; 0.397; 0.310	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	sphericity	-0.072	0.482; 0.104; -0.251; -0.334; -0.362	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	spiculation	0.159	0.227; 0.231; 0.080; 0.144; 0.113	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	subtlety	0.285	0.038; -0.027; 0.793; 0.559; 0.063	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance
Standard CBM	texture	-0.122	-0.155; 0.261; -0.227; -0.349; -0.137	DATA_NOT_PERSISTED	Signed centering evidence; constants are not importance

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T15.csv.


观察到了什么？不同 concept 与 model 的有符号贡献方向不同，说明相同 concept name 不一定具有相同决策角色。图 RPT-F10 把冻结逐样本点做成经验 OOF profile。该 profile 仅为描述性展示，不能读作 global causal shape function。权威 model-by-concept mean absolute aggregate 未持久化，因此报告将其标记为 DATA_NOT_PERSISTED，而不重新计算。

RPT-T16. Learned-softmax GAM 逐折 alpha

Fold	Concept	Expert 1	Expert 2	Expert 3	Expert 4	Expert 5	Min – max
0	calcification	0.200	0.200	0.204	0.196	0.199	0.196 – 0.204
0	internalStructure	0.200	0.200	0.200	0.200	0.200	0.200 – 0.200
0	lobulation	0.201	0.203	0.198	0.200	0.197	0.197 – 0.203
0	margin	0.198	0.198	0.203	0.202	0.200	0.198 – 0.203
0	sphericity	0.199	0.200	0.200	0.202	0.200	0.199 – 0.202
0	spiculation	0.194	0.200	0.200	0.200	0.207	0.194 – 0.207
0	subtlety	0.206	0.195	0.198	0.202	0.198	0.195 – 0.206
0	texture	0.201	0.200	0.199	0.200	0.200	0.199 – 0.201
1	calcification	0.195	0.191	0.201	0.201	0.211	0.191 – 0.211
1	internalStructure	0.201	0.199	0.199	0.199	0.201	0.199 – 0.201
1	lobulation	0.197	0.199	0.203	0.206	0.195	0.195 – 0.206
1	margin	0.202	0.200	0.199	0.199	0.201	0.199 – 0.202
1	sphericity	0.199	0.199	0.201	0.199	0.202	0.199 – 0.202
1	spiculation	0.200	0.203	0.205	0.195	0.197	0.195 – 0.205
1	subtlety	0.203	0.200	0.196	0.201	0.200	0.196 – 0.203
1	texture	0.202	0.200	0.199	0.198	0.201	0.198 – 0.202
2	calcification	0.200	0.196	0.206	0.199	0.199	0.196 – 0.206
2	internalStructure	0.199	0.199	0.201	0.201	0.201	0.199 – 0.201
2	lobulation	0.196	0.202	0.206	0.192	0.204	0.192 – 0.206
2	margin	0.201	0.199	0.198	0.200	0.202	0.198 – 0.202
2	sphericity	0.200	0.202	0.199	0.199	0.201	0.199 – 0.202
2	spiculation	0.207	0.201	0.202	0.196	0.193	0.193 – 0.207
2	subtlety	0.198	0.201	0.202	0.198	0.201	0.198 – 0.202
2	texture	0.201	0.199	0.199	0.199	0.201	0.199 – 0.201
3	calcification	0.198	0.203	0.200	0.196	0.202	0.196 – 0.203
3	internalStructure	0.201	0.200	0.199	0.199	0.201	0.199 – 0.201
3	lobulation	0.195	0.214	0.195	0.197	0.200	0.195 – 0.214
3	margin	0.200	0.203	0.199	0.200	0.198	0.198 – 0.203
3	sphericity	0.201	0.199	0.200	0.201	0.198	0.198 – 0.201
3	spiculation	0.203	0.203	0.192	0.200	0.201	0.192 – 0.203
3	subtlety	0.198	0.202	0.200	0.199	0.201	0.198 – 0.202
3	texture	0.200	0.199	0.200	0.201	0.199	0.199 – 0.201
4	calcification	0.203	0.206	0.195	0.193	0.202	0.193 – 0.206
4	internalStructure	0.200	0.201	0.199	0.201	0.199	0.199 – 0.201
4	lobulation	0.190	0.203	0.204	0.206	0.198	0.190 – 0.206
4	margin	0.201	0.200	0.199	0.200	0.201	0.199 – 0.201
4	sphericity	0.199	0.199	0.202	0.199	0.201	0.199 – 0.202
4	spiculation	0.198	0.201	0.198	0.203	0.199	0.198 – 0.203
4	subtlety	0.196	0.200	0.200	0.203	0.201	0.196 – 0.203
4	texture	0.199	0.199	0.200	0.202	0.200	0.199 – 0.202


完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T16.csv.

Learned-softmax GAM 增加第二层 WHY: 每个 concept 的五个 expert output 由非负且和为一的权重混合。表 RPT-T16 与图 RPT-F11 表明, 权重偏离均匀的 0.2 初始化, 但很多变化较小且依赖 fold。学习到的 mixture 是 optimisation evidence, 并不能证明每个 expert 对应不同临床机制。



RPT-F10. 经验 OOF 贡献剖面; 仅为描述性呈现, 并非因果 shape function。

这意味着什么? 贡献分解让评分构成可审计, 并支持病例层面有符号 bar, 但 magnitude 与 sign 仍是训练决策函数的属性, 不能验证底层概念或建立临床因果关系。私有定性附录把 contribution bar 与 CT context、concept prediction/target evidence 配对, 避免 WHY 脱离 WHAT 与 Prediction。



RPT-F11. Learned-softmax GAM 的逐折专家混合权重。

6.5 结果——HOW


测量内容是什么？概念干预按照预注册的模型特定语义替换 0…8 个 group。对每个 k，先拼接五折 OOF prediction，再计算主要 MAE 与次要 AUROC。random-permutation curve 对每折 100 个确定性 permutation 求均值；error-first 使用连续绝对误差或分类 total-variation distance 排序，不使用 malignancy target。

RPT-T17. 概念干预汇总

Model	Ordering	Baseline MAE	k=4 MAE	k=8 MAE	iMAE	Delta_iMAE	Baseline AUROC
Learned-softmax GAM	error_first	0.480	0.505	0.507	0.497	-0.016	0.949
Learned-softmax GAM	random_permutation	0.480	0.479	0.507	0.484	-0.003	0.949
Mixed-type CEM	error_first	0.484	0.440	0.436	0.445	0.040	0.942
Mixed-type CEM	random_permutation	0.484	0.454	0.436	0.456	0.028	0.942
Standard CBM	error_first	0.502	0.510	0.508	0.506	-0.004	0.933
Standard CBM	random_permutation	0.502	0.500	0.508	0.501	0.001	0.933

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T17.csv.

观察到了什么？Standard CBM 在随机顺序下平均 MAE 改善很小，在 error-first 积分下反而恶化。Mixed-type CEM 与 Learned-softmax GAM 在随机 permutation 下具有更大的正 Delta_iMAE，次要 Delta_iAUC pattern 同样依赖模型。表 RPT-T17 保留 baseline、intermediate、k=8、iMAE、Delta_iMAE、iAUC 与 Delta_iAUC；图 RPT-F12 展示完整 k=0...8 曲线。



RPT-F12. 随机顺序与 error-first 顺序下的 k=0...8 概念干预曲线。

error-first 并不始终优于随机顺序。首先纠正当前预测误差最大的概念，可能暴露模型其他位置的补偿误差；后续干预还可能逆转早期收益。这是重要负面结果，表明概念纠正不是单调 repair operation。

这意味着什么？HOW 证据检验模型对概念表示的依赖，而不是改变患者影像学表现的因果效应。正 Delta_iMAE 与 Delta_iAUC 始终表示改善，但 magnitude 依赖 architecture、ordering 与 metric。RPT-FA06 所需病例级 before/after intervention 未持久化，因此私有图把 HOW 标记为 DATA_NOT_PERSISTED，而不是伪造 trajectory。

科学结论代码：INTERVENTION_BENEFIT_MODEL_DEPENDENT

6.6 综合解释

Prediction、WHERE、WHAT、WHY、HOW 回答不同问题，不能压缩为单一 explainability score。Prediction 建立 task performance；WHERE 测试空间敏感性，但受全零图和较弱 matched-random 优势限制；WHAT 衡量命名概念是否匹配读者证据；WHY 暴露评分构成；HOW 探查纠正表示是否改变输出。

RPT-T18. WHERE-WHAT-WHY-HOW 综合表

Layer	Question	Main evidence	Boundary
Prediction	How accurately is malignancy scored?	Learned-softmax GAM has the lowest point-estimate MAE; paired support is model-dependent.	Radiologist assessment, not pathology.
WHERE	Where is the output spatially sensitive?	66,769 valid maps; saliency often did not exceed matched random masks.	6,955 post-ReLU zero maps; exact mechanism unavailable.
WHAT	Which concepts were predicted?	Continuous fidelity varied by concept; categorical hard-F1 was limited.	Categorical targets are reader-vote distributions.
WHY	How do concepts enter the score?	Signed centered terms and learned GAM mixtures reconstruct the score.	Centering constants are not importance; mean absolute aggregate was not persisted.
HOW	How does correcting concepts alter prediction?	Intervention benefit was strongest for CEM/GAM and ordering-dependent.	Interventions test model dependence, not causal clinical effects.

完整机器可读行与字段级 Catalogue provenance 保存在 RPT-T18.csv.

只有把这些层一起阅读，才能形成对模型最强的综合解释。Learned-softmax GAM 具有最佳主要点估计和可审计加性评分，但空间与干预证据仍有局限。Mixed-type CEM 即使分类概念忠实度不完美，仍从干预中明显获益。Standard CBM 简单、可追溯，却未相对 Black-box 获得预测优势。



综合结论：解释证据相互补充、依赖模型，并有明确边界

RPT-F13. Prediction-WHERE-WHAT-WHY-HOW 的综合解释及其边界。

因此，表 RPT-T18 与图 RPT-F13 呈现的是支持性 claim 与 boundary 链，而不是 winner-takes-all dashboard。结论是解释性具有多维度并依赖模型：有用解释必须说明它支持哪个层面、依赖什么冻结证据，以及不能建立什么。

7. 讨论

主要结果在点估计层面支持 Learned-softmax GAM；配对 MAE 比较支持其相对 Black-box 与 Standard CBM 的实质改善。这说明显式 concept-local nonlinearity 可以在保留加性分解的同时改善连续评分。然而，confidence interval 与次要判别结果阻止过度简单的排名：最佳回归点估计不等于在所有配对中 AUROC 都具有统计优势。

解释层揭示了单独预测指标看不到的 trade-off。概念模型提供 Black-box 缺少的 WHAT 与 WHY 证据，但概念准确度不均，分类 hard-F1 仍有限。CEM 与 GAM 的干预改善说明不完美预测概念会限制 task path，而其他设置中的恶化表明模型可能利用相关或补偿性概念误差。

空间证据提供最明确的谨慎信号。数千个合法 post-ReLU 全零图，以及总体较弱的 saliency-versus-random difference，意味着视觉上漂亮的 overlay 不应主导科学故事。Grad-CAM overlay 最适合被视为局部 sensitivity view；只有定量忠实度与 map-validity accounting 同时支持时，其可信度才增强。

从临床角度看，该框架提供的是规范沟通模型行为的方法，而不是诊断。读者评分编码影像学评估与分歧，并不建立组织病理学真实。任何临床主张都需要外部验证、部署校准、前瞻性流程测试与病理关联结局。

8. 局限性

第一，目标是放射科医师评估恶性评分，而不是病理确诊疾病。患者分组内部 cross-validation 控制 leakage，但不能建立对其他机构、扫描仪分布或临床流程的 transportability。每折只使用一个预注册 seed，因此 bootstrap interval 描述患者抽样不确定性，而不是训练 seed variability。

第二，concept ground truth 继承读者变异。连续均值压缩分歧，分类 vote distribution 可能稀疏。hard modal macro-F1 排除真实并列，并且次于完整分布指标。概念干预把内部表示替换为 reader-derived target，不能解释为可行临床操作或因果效应。

第三，Grad-CAM 是结节层面空间 proxy。6,955 个 undefined map 被确认为 finite post-ReLU 全零图，但精确 pre-ReLU/gradient mechanism 未持久化。因此，观察到的集中分布被报告为 SYSTEMATIC_MODEL/TARGET_ISSUE；在不允许新增 forward pass 的情况下，不能进一步断言是 zero gradient、zero channel weight 或 negative weighted sum。

最后，部分展示目标受冻结内容限制。model-by-concept mean absolute centered contribution aggregate 与病例级 intervention before/after trajectory 未持久化。报告明确标记这些条目为 DATA_NOT_PERSISTED，不会把描述性绘图或叙述记忆转成新的权威科学结果。

9. 结论

这项统一比较表明，预测与解释应作为一系列不同问题进行评估。Learned-softmax GAM 获得最低主要 MAE 点估计；配对不确定性同时指出该优势在哪些比较中明确、哪些比较中不明确。概念模型增加 Black-box predictor 无法提供的可检查表示、有符号评分分解与干预实验。

解释证据也带来具有实际意义的限制。概念忠实度不均、干预收益并非单调或普遍、Grad-CAM map 可能 undefined、显著区域遮挡经常不能优于匹配随机遮挡。这些不是边缘审计细节，而是决定每类解释能被多强地解读。

最终框架支持对放射科医师评估肺结节恶性程度进行透明、可复现的研究报告。它不建立病理层级诊断、因果概念、ground-truth localisation 或临床就绪性。其核心贡献是构建连接 Prediction、WHERE、WHAT、WHY、HOW 的可复现证据结构，同时让每个 claim 绑定冻结来源与解释边界。

公开可复现性附录

全部科学数值都来自用户批准的 2,395-item Results Catalogue 及其注册的冻结来源。报告修订 supplement 绑定 Catalogue registry SHA、Catalogue manifest SHA 与两份已批准计划文档 SHA。section manifest 与 reverse-traceability row 把每个渲染 table、figure、caption、conclusion code 连接到 Catalogue item ID 与 source hash。

P5 – P9 checkpoint、history、prediction、metric、evaluation、OOF row、intervention、Grad-CAM map、occlusion row 与 faithfulness payload 保持只读。报告生成不进行训练、model forward pass、test inference、bootstrap recomputation 或新 scientific job。私有 archive 保持在 Git 之外，并用 opaque CASE label 保存全分辨率病例资产。

Archive 包含 1,698 个文件、14,386,651,621 bytes，并由完成的 SHA-verified manifest 保护。六份 mandatory PDF 在 150 DPI 下用 Poppler 逐页渲染，通过 contact sheet 与原始分辨率页面检查，并使用 pypdf/pdfplumber 核对 metadata、text、numbering、font 与 page integrity，之后 P10 才能进入 AWAITING_USER_APPROVAL。

参考文献

[1] S. G. Armato III et al., "The Lung Image Database Consortium (LIDC) and Image Database Resource Initiative (IDRI): A completed reference database of lung nodules on CT scans," Med. Phys., vol. 38, no. 2, pp. 915-931, 2011, doi: 10.1118/1.3528204.

- [2] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely Connected Convolutional Networks," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), pp. 4700-4708, 2017, doi: 10.1109/CVPR.2017.243.
- [3] P. W. Koh et al., "Concept Bottleneck Models," in Proc. 37th Int. Conf. Mach. Learn. (ICML), PMLR, vol. 119, pp. 5338-5348, 2020.
- [4] M. Espinosa Zarlenga et al., "Concept Embedding Models: Beyond the Accuracy-Explainability Trade-Off," in Adv. Neural Inf. Process. Syst., vol. 35, pp. 21400-21413, 2022.
- [5] R. R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," in Proc. IEEE Int. Conf. Comput. Vis. (ICCV), pp. 618-626, 2017, doi: 10.1109/ICCV.2017.74.
- [6] B. Efron, "Bootstrap Methods: Another Look at the Jackknife," Ann. Stat., vol. 7, no. 1, pp. 1-26, 1979, doi: 10.1214/aos/1176344552.